

MIT 18.06 线性代数

第二十九讲：矩阵的 SVD 分解

整理自 MIT 18.06 课程及相关公开笔记

引言

奇异值分解 (Singular Value Decomposition, 简称 SVD) 是线性代数中一种用途广泛的矩阵分解方法。任意矩阵 A (包括长方形矩阵和奇异矩阵) 都可以分解为两个正交矩阵和一个对角矩阵的乘积形式: $A = U\Sigma V^T$ 。这一分解将矩阵的四个基本子空间联系起来, 是理解线性变换本质的重要工具, 在数据压缩、信号处理及最小二乘问题中有着广泛应用。

1 定义

对于任意 $m \times n$ 的矩阵 A , 其奇异值分解 (SVD) 表示为:

$$A = U\Sigma V^T$$

其中:

- U 是 $m \times m$ 的**正交矩阵**。
- Σ 是 $m \times n$ 的**对角矩阵**, 对角线上的元素称为**奇异值**, 且均为非负数, 通常按降序排列。
- V 是 $n \times n$ 的**正交矩阵**。

特殊情形: 若 A 是对称正定矩阵, 其 SVD 简化为 $A = Q\Lambda Q^T$ (即特征值分解), 此时 $U = V = Q$ 。对于一般矩阵, U 与 V 通常是不同的。

2 几何意义

可将矩阵 A 视为一个线性变换, 它将行空间中的向量映射到列空间中。SVD 的核心思想是: 在行空间中寻找一组**标准正交基** (Orthonormal Basis), 使得经过 A 变换后, 它们变成了列空间中的一组标准正交基。

数学表达为:

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \quad (i = 1, 2, \dots, r)$$

其中:

- $\mathbf{v}_1, \dots, \mathbf{v}_r$ 是行空间 $C(A^T)$ 的标准正交基。
- $\mathbf{u}_1, \dots, \mathbf{u}_r$ 是列空间 $C(A)$ 的标准正交基。
- σ_i 是**伸缩因子** (即奇异值)。

对于零空间中的向量 $\mathbf{v}_{r+1}, \dots, \mathbf{v}_n$ ，它们被 A 映射为零向量，对应 Σ 对角线上的零元素。同理，左零空间中的向量 $\mathbf{u}_{r+1}, \dots, \mathbf{u}_m$ 对应 Σ 中额外的零行/列。

2.1 矩阵形式的推导

将上述关系写成矩阵形式：

$$A \begin{bmatrix} \mathbf{v}_1 & \dots & \mathbf{v}_r & \mathbf{v}_{r+1} & \dots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} \mathbf{u}_1 & \dots & \mathbf{u}_r & \mathbf{u}_{r+1} & \dots & \mathbf{u}_m \end{bmatrix} \begin{bmatrix} \sigma_1 & & & & & \\ & \ddots & & & & \\ & & \sigma_r & & & \\ & & & 0 & & \end{bmatrix}$$

即 $AV = U\Sigma$ 。由于 V 是正交矩阵， $V^{-1} = V^T$ ，两边右乘 V^T 得到：

$$A = U\Sigma V^T$$

3 奇异值分解的计算方法

为了求得 U, Σ, V ，可以分别计算矩阵 $A^T A$ 和 AA^T 。

3.1 计算 V 与 Σ

考虑矩阵 $A^T A$ ，它是一个 $n \times n$ 的对称半正定矩阵，可以进行正交对角化：

$$A^T A = V \Sigma^T \Sigma V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{bmatrix} V^T$$

由此可得：

- V 的列向量是矩阵 $A^T A$ 的**特征向量**。
- 奇异值 σ_i 是 $A^T A$ 特征值 λ_i 的**正平方根**，即 $\sigma_i = \sqrt{\lambda_i}$ 。

3.2 计算 U

类似地，考虑矩阵 AA^T ($m \times m$ 对称半正定矩阵)：

$$AA^T = U \Sigma \Sigma^T U^T = U \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_m^2 \end{bmatrix} U^T$$

由此可得：

- U 的列向量是矩阵 AA^T 的**特征向量**。
- 注意， $A^T A$ 与 AA^T 的非零特征值是相同的，均为 σ_i^2 。

3.3 符号确定

在计算过程中，特征向量的符号并不唯一。一旦确定了 V （即确定了 $A^T A$ 的特征向量方向），则 U 的符号必须通过原关系式 $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ 来确定，即：

$$\mathbf{u}_i = \frac{1}{\sigma_i} A\mathbf{v}_i$$

这样可以避免直接通过 AA^T 求特征向量时可能出现的符号不一致问题。

4 奇异值分解的示例

4.1 示例一：可逆矩阵的 SVD

给定矩阵 $A = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$ ，求其 SVD。

1. 计算 $A^T A$ ：

$$A^T A = \begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} = \begin{bmatrix} 25 & 7 \\ 7 & 25 \end{bmatrix}$$

其特征值分别为 $\sigma_1^2 = 32$ 和 $\sigma_2^2 = 18$ ，对应单位特征向量为：

$$\mathbf{v}_1 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}$$

$$\text{因此 } V = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sqrt{32} & 0 \\ 0 & \sqrt{18} \end{bmatrix}.$$

2. 计算 AA^T ：

$$AA^T = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} \begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} = \begin{bmatrix} 32 & 0 \\ 0 & 18 \end{bmatrix}$$

其特征向量为 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 和 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 。

3. 确定符号：利用 $A\mathbf{v}_1 = \sigma_1 \mathbf{u}_1$ ，

$$A\mathbf{v}_1 = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} 8/\sqrt{2} \\ 0 \end{bmatrix} = \sqrt{32} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \implies \mathbf{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

同理， $A\mathbf{v}_2 = \begin{bmatrix} 0 \\ -6/\sqrt{2} \end{bmatrix} = \sqrt{18} \begin{bmatrix} 0 \\ -1 \end{bmatrix}$ ，故 $\mathbf{u}_2 = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$ 。因此 $U = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$ 。

4. 分解结果：

$$A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} \sqrt{32} & 0 \\ 0 & \sqrt{18} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}^T$$

4.2 示例二：奇异矩阵（秩亏矩阵）的 SVD

给定矩阵 $A = \begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix}$ ，它的秩为 1，即行空间和列空间都是一维的。

1. 行空间与列空间的标准正交基:

$$\mathbf{v}_1 = \begin{bmatrix} 0.8 \\ 0.6 \end{bmatrix}, \quad \mathbf{u}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

2. 计算 σ_1 : $A^T A$ 的迹为 $80 + 45 = 125$, 因此 $\sigma_1^2 = 125$, $\sigma_1 = \sqrt{125}$, 且 $\sigma_2 = 0$ 。

3. 确定补充的正交基: 行空间的补空间 (零空间) 可取 $\mathbf{v}_2 = \begin{bmatrix} 0.6 \\ -0.8 \end{bmatrix}$, 列空间的补空间 (左零空间) 可取 $\mathbf{u}_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ -1 \end{bmatrix}$ 。

4. 分解结果:

$$A = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} \sqrt{125} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0.8 & 0.6 \\ 0.6 & -0.8 \end{bmatrix}^T$$

5 四个基本子空间与 SVD

SVD 不仅给出了矩阵的分解, 还清晰地刻画了矩阵的四个基本子空间:

- $\mathbf{v}_1, \dots, \mathbf{v}_r$ 是行空间 (Row Space) $C(A^T)$ 的标准正交基。
- $\mathbf{u}_1, \dots, \mathbf{u}_r$ 是列空间 (Column Space) $C(A)$ 的标准正交基。
- $\mathbf{v}_{r+1}, \dots, \mathbf{v}_n$ 是零空间 (Nullspace) $N(A)$ 的标准正交基。
- $\mathbf{u}_{r+1}, \dots, \mathbf{u}_m$ 是左零空间 (Left Nullspace) $N(A^T)$ 的标准正交基。

这组基被称为“正确的基”, 因为在这些基下, 线性变换 A 的作用表现为简单的坐标伸缩, 即 $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ 。

总结

本讲系统介绍了奇异值分解 (SVD):

- 任意矩阵 A 均可分解为 $A = U\Sigma V^T$, 其中 U, V 是正交矩阵, Σ 是对角矩阵。
- SVD 将行空间的一组正交基映射为列空间的一组正交基, 奇异值 σ_i 控制伸缩比例。
- 通过求解 $A^T A$ 与 AA^T 的特征值和特征向量可以分别得到 V 和 U 。
- 奇异值分解是理解矩阵四个基本子空间的有力工具, 也是最小二乘问题、图像压缩等应用的理论基础。